

Corpus Size Model	Small (1.1 MB)	Medium (3.5 MB)	Large (11.5MB)	Very Large (35.5 MB)	Huge (120 MB)
Serial CPU	0.83	2.47	8.64	26.05	86.53
GPU + OpenMP	0.59	1.90	6.22	19.48	62.22
GPU + stream + OpenMP	0.59	1.90	6.48	19.15	62.40
GPU + stream + OpenMP	0.59	1.90	6.48	19.15	62.40

\*10 Execution

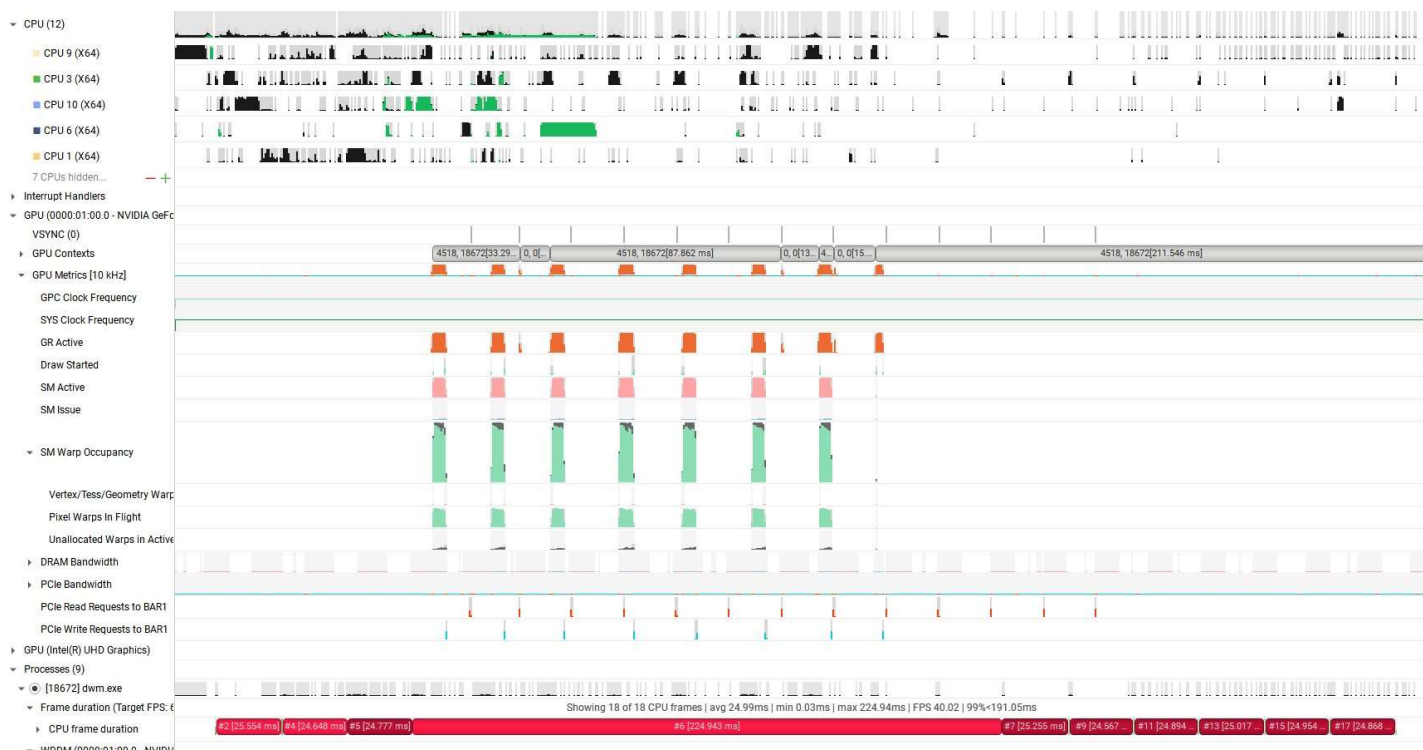
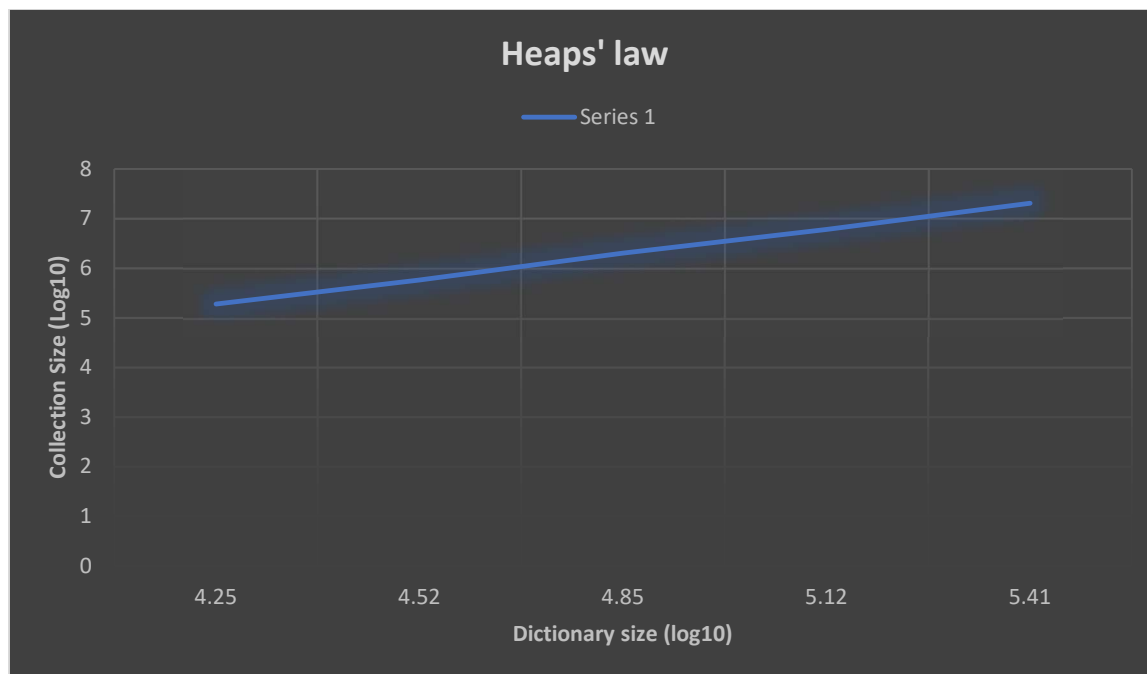
برای stemming از یک نوالگوریتم snowball استفاده شده است و tokenization به کمک کتابخانه ی boost پیاده سازی شده است. بعلاوه قبل از پردازش بروی متن با استفاده script های ساده که داخل فایل zip هستند، حروف noise را حذف کرده. برای stopword ها از یک لیست معتبر که در repository sentencepiece قرار داشت استفاده کردم. امکان موازی سازی عملیات ها در gpu مخصوصا stemming و tokenization وجود ندارد زیرا divergence بسیار زیاد است و با یک نگاه سطحی میتوان فهمید که شدنی نیست. تنها حالت ممکن استفاده از مدل های subword tokenization است که تمرین دادن آنها زمان زیادی میبرد و در این مدت زمان ممکن نبود. اگرچه حتی خود این مدل ها هم کاملاً مناسب نیستند (نمیتوان تمام بخش هارا موازی سازی کرد) برای بخش کار با openmp چالش هایی وجود دارد به طور مثال نمیتوان پیش پردازش را به تسک های ریز تقسیم کرد، چرا که از یک دیگر مستقل نیستند و باید به ترتیب اجرا شوند. تنها بخش موازی شده استفاده از نخ openmp برای اجرای kernel است به گونه ای که به یک نخ به عنوان وظیفه راه اندازی و اجرای کرنل cuda سپرده شده است. بیشتر پردازش در این قسمت برنامه بروی cpu است که از تصویر nsight systems هم معلوم است.

صلاحیت اسناد: یک معیار برای اندازه گیری کیفیت مجموعه اسناد اندازه گیری نسبت اندازه دیکشنری به تعداد کل کلمات است. با توجه به نمودار ترسیم شده که با قانون heaps همخوانی دارد میتوان گفت که اسناد به لحاظ تنوع کلمات مناسب هستند و حالت خاص نیستند.

چالش:

1. مسعله چه خواسته است
2. تحقیق اینکه چه چیز را میتوان موازی کرد و چه چیزی را نمیشه
3. انتظار چه speedup را باید داشته باشم
4. ترکیب تکنولوژی های مختلف مانند cuda, openmp چالش های زیادی داشت. Cmake را نمیشناختم. کامپایل و لینک کردن را بلد نبودم و داکيومنت خوب به اندازه ی کافی نبود.
5. انتظار اشتباه از مدل های مختلف داشتم به طور مثال فکر میکردم که sentencepiece یک tokenizer کامل است که اینطور نبود و زمان زیادی صرف راه اندازی آن هدر رفت.

SMALL: Most Frequent Word: (said:1590)	Dictionary Size: 17783	Total Counts: 192444
MED: Most Frequent Word: (said:4962)	Dictionary Size: 33401	Total Counts: 575106
LARGE: Most Frequent Word: (said:16521)	Dictionary Size: 70296	Total Counts: 2019437
VLAR: Most Frequent Word: (said:49456)	Dictionary Size: 132116	Total Counts: 6070588
HUGE: Most Frequent Word: (said:164635)	Dictionary Size: 260695	Total Counts: 20236831



قسمت زیرین تنها مربوط به اجرای الگوریتم histogram است. Speedup ها به نسبت حالت سریال محاسبه شده اند. در کل به دلیل اینکه حجم پردازش بسیار نیست به دسترسی و کار با حافظه کمتر است گرفتن speedup خیلی بالا در حالت استفاده از stream زیاد نیست. در پایین هم در عکس تحلیل nsight systems قابل مشاهده است که حتی با اینکه کرنل ها با حافظه موازی شده اند همچنان مقدار زیادی از زمان gpu محاسبه انجام نمیدهد. مخصوصاً اینکه خود استفاده از عملیات اتمی هزینه بالایی دارد و قابل پیاده سازی در shared memory برای تعداد bin های بالا (تعداد کلمات دیکشنری) را ندارد. البته میتوان از روش data

output decomposition استفاده کرد که لازمه ی آن حرکت هر نخ بروی کل آرایه ها است که طبیعتا قرار نیست speedup بدهد.

تصویر اولی برای حالت بدون shared memory و دومی برای حالت با shared memory است. Record.txt شامل اجرا های مختلف الگوریتم histogram است.

